



# Probabilistic Graphical Model

Final Project.

---

**Ali Izadi**

**810199102**


## فهرست مطالب

۱	فهرست مطالب
۲	بخش اول: رویکرد Bayesian
۷	بخش دوم: استفاده از داده‌های شبکه‌های اجتماعی
۱۶	بخش سوم: پیاده سازی
۱۹	بخش چهارم: نتایج

## بخش اول: رویکرد Bayesian

هدف از این بخش یادگیری دو ماتریس  $U$  و  $V$  است. بنابراین نیاز به محاسبه توزیع posterior زیر داریم که مطابق با مدل گرافیکی احتمالی آن به صورت زیر factorize میشود:

$$P(U, V | R) = P(R | U, V, \sigma) \cdot P(U | \sigma_U) \cdot P(V | \sigma_V) \cdot P(\sigma_U | \alpha_U, \beta_U) \cdot P(\sigma_V | \alpha_V, \beta_V)$$



دو ماتریس  $U$  و  $V$  را با استفاده از gibbs sampling تخمین میزنیم.

برای این کار نیاز به محاسبه احتمالات complete conditional متغیرهای نهان داریم. یعنی محاسبه دو ماتریس  $U$  و  $V$  و  $\sigma$  های  $U$  و  $V$ .

- ابتدا به محاسبه complete conditional ماتریس  $U$  میپردازیم. چون  $U_i$  ها از هم مستقل اند احتمال شرطی  $U_i$  به شرط بقیه متغیرها را مطابق با زیر محاسبه میکنیم

$$P(U_i | R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V) = \frac{P(U_i, R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V)}{\sum_{U_i} P(U_i, R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V)}$$

- توزیع joint را مطابق با مدل احتمالاتی factorize میکنیم و آن متغیرهایی که به  $U_i$  وابسته نیستند را از صورت و مخرج حذف میکنیم.

$$\begin{aligned}
 P(U_i | R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V) &= \frac{P(U_i, R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V)}{\sum_{U_i} P(U_i, R, V, \sigma, \sigma_U, \sigma_V, \alpha_U, \beta_U, \alpha_V, \beta_V)} \\
 &= \frac{P(R | U_i, V, \sigma) \cdot P(U_i | \sigma_U)}{\sum_{U_i} P(R | U_i, V, \sigma) \cdot P(U_i | \sigma_U)} \\
 &\propto P(R | U_i, V, \sigma) \cdot P(U_i | \sigma_U)
 \end{aligned}$$

- در نتیجه complete conditional متناسب با توزیع بالا به دست می آید.  
 حال توزیع به دست آمده را بسط میدهیم (روابط توزیع نرمال را مینویسم و توان دوی به دست آمده را نیز باز میکنیم).  $I_j$  نیز به این معناست که کاربر  $i$  به زامین item امتیاز داده است.

$$\begin{aligned}
 \log P(R | U_i, V, \sigma) \cdot P(U_i | \sigma_U) &= \log \left( \left( \prod_{j=1}^M N(R_{ij} | U_i^T V_j, \sigma) \right)^{I_{ij}} \cdot N(U_i | 0, \sigma_U I) \right) \\
 &\propto \left( \sum_{j=1}^M -\frac{I_{ij}}{2\sigma} (R_{ij} - U_i^T V_j)^2 \right) - \frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i \\
 &= \left( \sum_{j=1}^M -\frac{I_{ij}}{2\sigma} (R_{ij}^2 + (U_i^T V_j)^2 - 2R_{ij} U_i^T V_j) \right) - \frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i
 \end{aligned}$$

- حال فرم quadratic را نوشته و تنها متغیرهای وابسته به  $U_i$  را نگه میداریم زیرا complete conditional بر حسب  $U_i$  است.

$$\begin{aligned}
 \log P(R | U_i, V, \sigma) \cdot P(U_i | \sigma_U) &\propto \left( \sum_{j=1}^M -\frac{I_{ij}}{2\sigma} (R_{ij}^2 + (U_i^T V_j)^2 - 2R_{ij} U_i^T V_j) \right) - \frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i \\
 &= \left( \sum_{j=1}^M -\frac{I_{ij}}{2\sigma} (U_i^T V_j V_j^T U_i) \right) - \frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i + \left( \sum_{j=1}^M -\frac{I_{ij}}{2\sigma} (-2R_{ij} U_i^T V_j) \right)
 \end{aligned}$$

- چون فرم به دست آمده quadratic است پس از یک توزیع نرمال پیروی میکند و بنابراین توزیع نرمال complete conditional برای  $U_i$  مطابق با زیر به دست می آید.

$$U_i \sim N(\mu, \Sigma)$$

$$\Sigma^{-1} = \left( (\sigma_U I)^{-1} + \frac{1}{\sigma} \sum_{j=1}^M I_{ij} V_j V_j^T \right)$$

$$\mu = \Sigma \cdot \left( \frac{1}{\sigma} \sum_{j=1}^M I_{ij} (R_{ij} V_j^T) \right)$$

- 
- مشابه با آن چه برای محاسبه  $U_i$  به دست آمد روابط زیر برای  $V_j$  نیز به دست می آید که از یک توزیع نرمال مطابق با زیر پیروی میکند.

$$V_j \sim N(\mu, \Sigma)$$

$$\Sigma^{-1} = \left( (\sigma_V I)^{-1} + \frac{1}{\sigma} \sum_{i=1}^N I_{ij} U_i U_i^T \right)$$

$$\mu = \Sigma \cdot \left( \frac{1}{\sigma} \sum_{i=1}^N I_{ij} (R_{ij} U_i^T) \right)$$


---

- حال از متغیرهای نهان باقیمانده به سراغ محاسبه complete conditional سیگمای U میرویم. در رابطه های پایین ~ به معنای بقیه متغیرهاست.

مطابق با قبل توزیع بر اساس مدل احتمالی factorize میشود و هم چنین توزیع هایی که به سیگمای U وابسته نیستند از صورت و مخرج حذف میشوند.

$$\begin{aligned}
 P(\sigma_U | \sim) &= \frac{P(\sigma_U, \sim)}{\sum_{\sigma_U} P(\sigma_U, \sim)} \\
 &= \frac{P(U | \sigma_U) \cdot P(\sigma_U | \alpha_U, \beta_U)}{\sum_{\sigma_U} P(U | \sigma_U) \cdot P(\sigma_U | \alpha_U, \beta_U)} \\
 &\propto P(U | \sigma_U) \cdot P(\sigma_U | \alpha_U, \beta_U)
 \end{aligned}$$

- در نتیجه complete conditional متناسب با توزیع بالا به دست می آید.

حال توزیع به دست آمده را بسط میدهیم (روابط توزیع نرمال و گاما را مینویسم)

توزیع نرمال زیر چون دارای سیگمای ثابت در ابعاد D تایی آن است پس میتوان آن را به صورت ضرب D توزیع نرمال نوشت تا بتوان نتیجه را با توزیع gamma inverse ترکیب کرد.

$$\begin{aligned}
 P(U | \sigma_U) \cdot P(\sigma_U | \alpha_U, \beta_U) &= \left( \prod_{i=1}^N N(0, \sigma_U I) \right) \cdot \text{invgamma}(\sigma_U | \alpha_U, \beta_U) \\
 &= \left( \prod_{i=1}^N \frac{1}{|\sigma_U I|^{0.5}} \exp \left( \frac{-1}{2} U_i^T (\sigma_U I)^{-1} U_i \right) \right) \cdot \left( \frac{1}{\sigma_U} \right)^{\alpha_U + 1} \cdot \exp \left( \frac{-\beta}{\sigma_U} \right) \\
 &= \left( \prod_{i=1}^N \prod_{d=1}^D \frac{1}{\sigma_{Ud}^{0.5}} \exp \left( \frac{-1}{2\sigma_{Ud}} U_{id}^2 \right) \right) \cdot \left( \frac{1}{\sigma_U} \right)^{\alpha_U + 1} \cdot \exp \left( \frac{-\beta}{\sigma_U} \right) \\
 &= \exp \left( \left( \sum_{i=1}^N \sum_{d=1}^D \frac{-1}{2\sigma_U} U_{id}^2 \right) - \frac{\beta}{\sigma_U} \right) \cdot \left( \frac{1}{\sigma_U} \right)^{\frac{N \times D}{2} + \alpha_U + 1}
 \end{aligned}$$

- در نتیجه توزیع complete conditional برای سیگمای  $U$  از فرم توزیع gamma inverse پیروی میکند با  $\alpha_U$  و  $\beta_U$  جدید که مطابق با زیر به دست می آید.

$$\sigma_U \sim Invgamma(\alpha_U, \beta_U)$$

$$\alpha_U = \alpha_U + \frac{N \times D}{2}$$

$$\beta_U = \beta_U + \sum_{i=1}^N \sum_{d=1}^D \frac{1}{2} U_{id}^2$$

- مشابه با آن چه برای محاسبه سیگمای  $U$  به دست آمد روابط زیر برای سیگمای  $V$  نیز به دست می آید که از یک توزیع gamma inverse مطابق با زیر پیروی میکند.

$$\sigma_V \sim Invgamma(\alpha_V, \beta_V)$$

$$\alpha_V = \alpha_V + \frac{M \times D}{2}$$

$$\beta_V = \beta_V + \sum_{j=1}^M \sum_{d=1}^D \frac{1}{2} V_{jd}^2$$

## بخش دوم: استفاده از داده‌های شبکه‌های اجتماعی

همان طور که در صورت سوال ذکر شده میانگین توزیع امتیازات علاوه بر وابستگی به ماتریس‌های  $U$  و  $V$  به جمع وزن دار امتیازات دوستان فرد نیز وابسته است. وزن‌ها تاثیر هر فرد روی فرد دیگر را نشان میدهد و در این مسئله یک متغیر نهان بوده و مشابه با دیگر متغیرهای نهان نیاز به یادگیری دارد. همان طور که در رابطه‌ی زیر مشاهده میشود امتیاز فرد  $i$  به زامین item علاوه بر ضرب داخلی  $U_i$  در  $V_j$  به علاوه‌ی مقدار زیر نیز میشود:

برای هر همسایه کاربر  $i$ :

(ضریب  $W_{ik}$  که مربوط به تاثیر کاربر  $i$  و همسایه آن یعنی  $k$  است)

ضربدر

(امتیازی که همسایه آن به زامین item)

و برای همه همسایه‌های کاربر  $i$  این مقدار جمع میشود.

$$R_{ij} \sim N \left( \left( U_i^T V_j + \sum_{k \in \text{neighbor}(i)} W_{ik} R_{kj}^{I_{kj}} \right), \sigma \right)$$

- مشابه با قبل نیاز به محاسبه توزیع احتمال posterior متغیرهای نهان داریم که در این بخش علاوه بر متغیرهای قبلی  $W$  نیز اضافه شده است.

$$P(U, V, W, \sigma_U, \sigma_V | R) = \frac{P(R | U, V, W, \sigma) \cdot P(U | \sigma_U) \cdot P(V | \sigma_V) \cdot P(\sigma_U | \alpha_U, \beta_U) \cdot P(\sigma_V | \alpha_V, \beta_V)}{\int P(R | U, V, W, \sigma) \cdot P(U | \sigma_U) \cdot P(V | \sigma_V) \cdot P(\sigma_U | \alpha_U, \beta_U) \cdot P(\sigma_V | \alpha_V, \beta_V)}$$



- برای محاسبه عبارت بالا از روش variational mean field مطابق با روش خواسته شده در صورت سوال استفاده میکنیم.

- در نتیجه از توزیع تقریبی Q استفاده میکنیم که روی متغیرهای نهان مطابق با زیر factorize میشود.

$$Q(U, V, W, \sigma_U, \sigma_V) = Q(U) \cdot Q(V) \cdot Q(W) \cdot Q(\sigma_U) \cdot Q(\sigma_V)$$

- در نتیجه میتوانیم توزیع Q روی هر متغیرنهان را با استفاده از variational optimization به دست آوریم.

- ابتدا به محاسبه توزیع ماتریس U با استفاده از این روش خواهیم پرداخت.  
مطابق با variational optimization توزیع Q از رابطه زیر به دست می آید.

$$\ln Q(U) = E_{\sim U}[\ln P(U, V, W, \sigma_U, \sigma_V, R)]$$

- حال سمت راست و توزیع p را مطابق با مدل احتمالاتی factorize میکنیم و آن termهایی که به U وابسته نیستند را نیز حذف کرده و به عنوان constant در نظر میگیریم. هم چنین توزیع W را 0 در نظر میگیریم تا در عبارات به constant تبدیل شود.

$$\begin{aligned} \ln Q(U) &= E_{\sim U}[\ln P(U, V, W, \sigma_U, \sigma_V, R)] \\ &= E_{\sim U} \left[ \left( \sum_{i=1}^N \sum_{j=1}^M \ln N \left( R_{ij} \middle| U_i^T V_j + \sum_{k \in \text{neighbor}(i)} W_{ik} R_{kj}^{I_{kj}}, \sigma \right) \right) + \sum_{i=1}^N \ln N(U_i | 0, \sigma_U) \right] + \text{const} \end{aligned}$$

- همان طور که مشاهده میشود عبارت به دست آمده مطابق با زیر روی  $U_i$  ها نیز factorize میشود و بنابراین میتوان در ادامه توزیع  $U_i$  را محاسبه کرد.

$$\ln Q(U) = \sum_{i=1}^N \ln Q(U_i) \implies Q(U) = \prod_{i=1}^N Q(U_i)$$

- برای محاسبه توزیع  $U_i$  ها عبارات به دست آمده از مرحله قبل که همه شامل  $U_i$  هستند را بسط میدهیم (توزیع نرمال را مینویسیم).
- توان دوی به دست آمده در زیر را نیز باز کرده و تنها عباراتی که به  $U_i$  وابسته هستند را نگه میداریم.
- سپس امیدریاضی را محاسبه میکنیم که در عباراتی که متغیرهای نهان غیر از  $U_i$  وجود دارد از آن ها امید ریاضی گرفته میشود.

$$\begin{aligned} \ln Q(U_i) &= E_{\sim U_i} \left[ \left( \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( R_{ij} - U_i^T V_j - \sum_{k \in \text{neighbor}(i)} W_{ik} R_{kj}^{I_{kj}} \right)^2 \right) \right] \\ &\quad + E_{\sim U_i} \left[ -\frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i \right] \\ &= E_{\sim U_i} \left[ \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( (U_i^T V_j)^2 - 2R_{ij} V_j^T U_i - 2 \left( \sum_{k \in \text{neighbor}(i)} W_{ik} R_{kj}^{I_{kj}} \right) \cdot (V_j^T U_i) \right) \right] \\ &\quad + E_{\sim U_i} \left[ -\frac{1}{2} U_i^T (\sigma_U I)^{-1} U_i \right] \\ &= \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( U_i^T E[V_j V_j^T] U_i - 2R_{ij} E[V_j^T] U_i - 2 \sum_{k \in \text{neighbor}(i)} E[W_{ik}] R_{kj}^{I_{kj}} \cdot E[V_j^T] U_i \right) \\ &\quad - \frac{1}{2} U_i^T (E[\sigma_U] I)^{-1} U_i \\ &\implies E[V_j V_j^T] = \Sigma_{V(j)}^{new} + \left( \mu_{V(j)}^{new} \right)^2, E[V_j^T] = \mu_{V(j)}^{new}, E[\sigma_U] = \frac{\beta_U^{new}}{\alpha_U^{new} - 1}, E[W_{ik}] = \mu_{W(ik)}^{new} \\ &= \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( U_i^T \left( \Sigma_{V(j)}^{new} + \left( \mu_{V(j)}^{new} \right)^2 \right) U_i \right) + \sum_{j=1}^M \frac{I_{ij}}{\sigma} \left( R_{ij} \mu_{V(j)}^{new} U_i \right) \\ &\quad + \sum_{j=1}^M \sum_{k \in \text{neighbor}(i)} \frac{I_{ij}}{\sigma} \mu_{W(ik)}^{new} R_{kj}^{I_{kj}} \mu_{V(j)}^{new} U_i - \frac{1}{2} U_i^T \left( \left( \frac{\beta_U^{new}}{\alpha_U^{new} - 1} \right) I \right)^{-1} U_i \end{aligned}$$

- هم چنین در عبارات بالا امیدریاضی ها به دست آمده از متغیرهای نهان بر اساس توزیع های آن ها (قسمت نتیجه) جایگذاری شده اند.
- چون فرم به دست آمده quadratic است پس از یک توزیع نرمال پیروی میکند و بنابراین توزیع نرمال variational برای  $U_i$  مطابق با زیر به دست می آید.

$$U_i \sim N\left(\mu_{U(i)}^{new}, \Sigma_{U(i)}^{new}\right)$$

$$\left(\Sigma_{U(i)}^{new}\right)^{-1} = \left(\left(\left(\frac{\beta_U^{new}}{\alpha_U^{new} - 1}\right)I\right)^{-1} + \frac{1}{\sigma} \sum_{j=1}^M I_{ij} \left(\Sigma_{V(j)}^{new} + \left(\mu_{V(j)}^{new}\right)^2\right)\right)$$

$$\mu_{U(i)}^{new} = \Sigma_{U(i)}^{new} \left( \sum_{j=1}^M \frac{I_{ij}}{\sigma} \left( R_{ij} \mu_{V(j)}^{new} + \sum_{k \in neighbor(i)} \mu_{W(ik)}^{new} R_{kj}^{I_{kj}} \mu_{V(j)}^{new} \right) \right)$$

- مشابه با آن چه برای محاسبه  $U_i$  به دست آمد روابط زیر برای  $V_i$  نیز به دست می آید که از یک توزیع نرمال مطابق با زیر پیروی میکند.

$$V_j \sim N\left(\mu_{V(j)}^{new}, \Sigma_{V(j)}^{new}\right)$$

$$\left(\Sigma_{V(j)}^{new}\right)^{-1} = \left(\left(\left(\frac{\beta_V^{new}}{\alpha_V^{new} - 1}\right)I\right)^{-1} + \frac{1}{\sigma} \sum_{i=1}^N I_{ij} \left(\Sigma_{U(i)}^{new} + \left(\mu_{U(i)}^{new}\right)^2\right)\right)$$

$$\mu_{V(j)}^{new} = \Sigma_{V(j)}^{new} \left( \sum_{i=1}^N \frac{I_{ij}}{\sigma} \left( R_{ij} \mu_{U(i)}^{new} + \sum_{k \in neighbor(i)} \mu_{W(ik)}^{new} R_{kj}^{I_{kj}} \mu_{U(i)}^{new} \right) \right)$$

• حال محاسبه توزیع سیگمای  $U$  با استفاده از روش variational مطابق با قبل خواهیم پرداخت.

مطابق با variational optimization توزیع  $Q$  از رابطه زیر به دست می آید.

برای محاسبه توزیع سیگمای  $U$  عباراتی که همه شامل سیگمای  $U$  هستند را بسط میدهیم (توزیع نرمال و گاما را مینویسیم).

توزیع نرمال زیر را به صورت ضرب  $D$  توزیع نرمال نوشت تا بتوان نتیجه را با توزیع gamma inverse ترکیب کرد.

سپس امیدریاضی را محاسبه میکنیم که در عباراتی که متغیرهای نهان غیر از سیگمای  $U$  وجود دارد از آن ها امید ریاضی گرفته میشود.

$$\begin{aligned}
 \ln Q(\sigma_u) &= E_{\sim \sigma_u} [\ln P(U, V, W, \sigma_U, \sigma_V, R)] \\
 &= E_{\sim \sigma_u} \left[ \ln \left( \left( \prod_{i=1}^N N(U_i | 0, \sigma_u I) \right) \cdot invgamma(\sigma_u | \alpha_U, \beta_u) \right) \right] \\
 &= E_{\sim \sigma_u} \left[ \ln \left( \left( \prod_{i=1}^N \frac{1}{|\sigma_u I|^{0.5}} \exp \left( \frac{-1}{2} U_i^T (\sigma_u I)^{-1} U_i \right) \right) \cdot \left( \frac{1}{\sigma_u} \right)^{\alpha_U+1} \cdot \exp \left( \frac{-\beta}{\sigma_u} \right) \right) \right] \\
 &= E_{\sim \sigma_u} \left[ \ln \left( \left( \prod_{i=1}^N \prod_{d=1}^D \frac{1}{\sigma_{ud}^{0.5}} \exp \left( \frac{-1}{2\sigma_{ud}} U_{id}^2 \right) \right) \cdot \left( \frac{1}{\sigma_u} \right)^{\alpha_U+1} \cdot \exp \left( \frac{-\beta}{\sigma_u} \right) \right) \right] \\
 &= \ln \left( \left( \prod_{i=1}^N \prod_{d=1}^D \frac{1}{\sigma_{ud}^{0.5}} \exp \left( \frac{-1}{2\sigma_{ud}} E[U_{id}^2] \right) \right) \cdot \left( \frac{1}{\sigma_u} \right)^{\alpha_U+1} \cdot \exp \left( \frac{-\beta}{\sigma_u} \right) \right) \\
 &\implies E[U_{id}^2] = \left( \mu_{U(i,d)}^{new} \right)^2 + \Sigma_{U(idd)}^{new} \\
 &= \ln \left( \left( \prod_{i=1}^N \prod_{d=1}^D \frac{1}{\sigma_{ud}^{0.5}} \exp \left( \sum_{i=1}^N \sum_{d=1}^D \frac{-1}{2\sigma_{ud}} \left( \left( \mu_{U(i,d)}^{new} \right)^2 + \Sigma_{U(idd)}^{new} \right) \right) \right) \cdot \left( \frac{1}{\sigma_u} \right)^{\alpha_U+1} \cdot \exp \left( \frac{-\beta}{\sigma_u} \right) \right) \\
 &= \ln \left( \left( \frac{1}{\sigma_u} \right)^{\frac{N \times D}{2} + \alpha_U+1} \cdot \exp \left( \sum_{i=1}^N \sum_{d=1}^D \frac{-1}{2\sigma_{ud}} \left( \left( \mu_{U(i,d)}^{new} \right)^2 + \Sigma_{U(idd)}^{new} \right) + \frac{-\beta}{\sigma_u} \right) \right) \\
 &\implies \\
 Q(\sigma_u) &= \left( \frac{1}{\sigma_u} \right)^{\frac{N \times D}{2} + \alpha_U+1} \cdot \exp \left( \sum_{i=1}^N \sum_{d=1}^D \frac{-1}{2\sigma_u} \left( \left( \mu_{U(i,d)}^{new} \right)^2 + \Sigma_{U(idd)}^{new} \right) + \frac{-\beta}{\sigma_u} \right)
 \end{aligned}$$

- هم چنین در عبارات بالا امیدریاضی ها به دست آمده از متغیرهای نهان بر اساس توزیع های آن ها(قسمت نتیجه) جایگذاری شده اند.

- در نتیجه توزیع variational برای سیگمای U از فرم توزیع gamma inverse پیروی میکند با alpha و beta جدید که مطابق با زیر به دست می آید.

پس

$$\sigma_U \sim \text{Invgamma}(\alpha_U^{\text{new}}, \beta_U^{\text{new}})$$

$$\alpha_U^{\text{new}} = \alpha_U + \frac{N \times D}{2}$$

$$\beta_U^{\text{new}} = \beta_U + \sum_{i=1}^N \sum_{d=1}^D \frac{1}{2} \left( \left( \mu_{U(id)}^{\text{new}} \right)^2 + \Sigma_{U(idd)}^{\text{new}} \right)$$

- مشابه با آن چه برای محاسبه سیگمای U به دست آمد روابط زیر برای سیگمای V نیز به دست می آید که از یک توزیع gamma inverse مطابق با زیر پیروی میکند.

•

$$\sigma_V \sim \text{Invgamma}(\alpha_V^{\text{new}}, \beta_V^{\text{new}})$$

$$\alpha_V^{\text{new}} = \alpha_V + \frac{N \times D}{2}$$

$$\beta_V^{\text{new}} = \beta_V + \sum_{j=1}^M \sum_{d=1}^D \frac{1}{2} \left( \left( \mu_{V(jd)}^{\text{new}} \right)^2 + \Sigma_{V(jdd)}^{\text{new}} \right)$$

- حال محاسبه توزیع  $W$  با استفاده از روش variational مطابق با قبل خواهیم پرداخت.

سمت راست و توزیع  $p$  را مطابق با مدل احتمالاتی factorize میکنیم و آن termهایی که به  $W$  وابسته نیستند را نیز حذف کرده و به عنوان constant در نظر میگیریم.

$$\ln Q(W) = E_{\sim W}[\ln P(U, V, W, \sigma_U, \sigma_V, R)]$$

$$\begin{aligned} \ln Q(W) &= E_{\sim W}[\ln P(U, V, W, \sigma_U, \sigma_V, R)] \\ &= E_{\sim W} \left[ \sum_{i=1}^N \sum_{j=1}^M \ln N \left( R_{ij} \middle| U_i^T V_j + \sum_{k \in \text{neighbor}(i)} W_{ik} R_{kj}^{I_{kj}}, \sigma \right) \right] + \text{const} \end{aligned}$$

- همان طور که مشاهده میشود عبارت به دست آمده مطابق با زیر روی  $W_{ik}$  ها نیز factorize میشود و بنابراین میتوان در ادامه توزیع  $W_{ik}$  را محاسبه کرد.

$$\ln Q(W) = \sum_{i=1}^N \sum_{k \in \text{neighbor}(i)} \ln Q(W_{ik}) \implies Q(W) = \prod_{i=1}^N \prod_{k \in \text{neighbor}(i)} Q(W_{ik})$$

- برای محاسبه توزیع  $W_{ik}$  ها عبارات به دست آمده از مرحله قبل که همه شامل  $W_{ik}$  هستند را بسط میدهیم (توزیع نرمال را مینویسیم).  
توان دوی به دست آمده در زیر را نیز باز کرده و تنها عباراتی که به  $W_{ik}$  وابسته هستند را نگه میداریم.  
سپس امیدریاضی را محاسبه میکنیم که در عباراتی که متغیرهای نهان غیر از  $W_{ik}$  وجود دارد از آن ها امید ریاضی گرفته میشود.

$$\begin{aligned}
 \ln Q(W_{ik}) &= E_{\sim W_{ik}} \left[ \left( \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( R_{ij} - U_i^T V_j - W_{ik} R_{kj}^{I_{kj}} \right)^2 \right) \right] \\
 &= E_{\sim W_{ik}} \left[ \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( \left( W_{ik} R_{kj}^{I_{kj}} \right)^2 + 2U_i^T V_j W_{ik} R_{kj}^{I_{kj}} - 2R_{ij} W_{ik} R_{kj}^{I_{kj}} \right) \right] \\
 &= \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( \left( R_{kj}^{I_{kj}} \right)^2 \cdot W_{ik}^2 + 2E[U_i^T] E[V_j] W_{ik} R_{kj}^{I_{kj}} - 2R_{ij} R_{kj}^{I_{kj}} W_{ik} \right) \\
 &\implies E[U_i^T] = \mu_{U(i)}^{new}, E[V_j^T] = \mu_{V(j)}^{new} \\
 &= \sum_{j=1}^M \frac{-I_{ij}}{2\sigma} \left( \left( R_{kj}^{I_{kj}} \right)^2 \cdot W_{ik}^2 + 2\left( \mu_{U(i)}^{new} \right)^T \mu_{V(j)}^{new} R_{kj}^{I_{kj}} W_{ik} - 2R_{ij} R_{kj}^{I_{kj}} W_{ik} \right)
 \end{aligned}$$

- هم چنین در عبارات بالا امیدریاضی ها به دست آمده از متغیرهای نهان بر اساس توزیع های آن ها (قسمت نتیجه) جایگذاری شده اند.

- چون فرم به دست آمده quadratic است پس از یک توزیع نرمال پیروی میکند و بنابراین توزیع نرمال variational برای  $W_{ik}$  مطابق با زیر به دست می آید.

$$W_{ik} \sim N\left(\mu_{W(i,k)}^{new}, \sigma_{W(i,k)}^{new}\right)$$

$$\left(\sigma_{W(i,k)}^{new}\right)^{-1} = \left(\frac{1}{\sigma} \sum_{j=1}^M I_{ij} \left(R_{kj}^{I_{kj}}\right)^2\right)$$

$$\mu_{W(i,k)}^{new} = \sigma_{ik} \left( \sum_{j=1}^M I_{ij} \left( R_{ij} R_{kj}^{I_{kj}} - \left( \mu_{U(i)}^{new} \right)^T \mu_{V(j)}^{new} R_{kj}^{I_{kj}} \right) \right)$$

---

در نتیجه توزیع هر کدام از متغیرهای نهان به دست آمد.

همان طور که مشاهده میشود توزیع ها به هم وابستگی دارند (به عنوان مثال توزیع  $U$  به میانگین توزیع  $V$  وابسته است). بنابراین با شروع از  $U$  به ترتیب  $V$ ، سیگمای  $U$ ، سیگمای  $V$  و در نهایت  $W$  تخمین زده میشود و تا convergence این کار ادامه میابد.

- در ادامه پیاده سازی انجام شده و نتایج به دست آمده را بررسی خواهیم کرد.



## بخش سوم: پیاده سازی

پیاده سازی قسمت اول در فایل `gibbs_sampling.py` و قسمت دوم در فایل `variational_mean_field.py` انجام شده

### Gibbs sampling:

در این بخش در هر مرحله مطابق با روابط به دست آمده ماتریس‌های  $U$  و  $V$  و سپس سیگمای  $U$  و سیگمای  $V$  بر اساس توزیع‌های هر کدام نمونه برداری میشوند.

- مقادیر اولیه ماتریس‌های  $U$  و  $V$  و سیگمای  $U$  و سیگمای  $V$  نیز بر اساس توزیع‌های اولیه آن‌ها و با مقادیر اولیه فرایارامترهای  $\sigma, \alpha_U, \alpha_V, \beta_U, \beta_V$  نمونه برداری شده‌اند.
- برای هر  $user$  و  $item$  چون مستقل از هم در نظر گرفته شده‌اند بنابراین نمونه برداری ماتریس‌های  $U$  و  $V$  نیز به صورت مستقل بر روی  $user$  و  $item$  انجام شده است.

در انتها بر اساس ماتریس‌های  $U$  و  $V$  نمونه برداری شده از ضرب داخلی این دو بردار  $R_{hat}$  به دست می‌آید. سپس نتیجه با استفاده از `MinMaxScaler` به بازه بین صفر تا پنج `scale` میشود.

برای محاسبه `RMSE` مراحل آموزش در هر مرحله تفاوت بین  $R_{hat}$  و جاهایی که در ماتریس  $R$  امتیاز وجود دارد (غیر صفرها) محاسبه میشود.

در نهایت با استفاده از ماتریس‌های  $U$  و  $V$  نهایی مقدار خطا مشابه با قبل برای داده‌های `validation` محاسبه شده است.

## :Variational Mean Field

در این بخش ابتدا همسایگی‌های هر فرد در یک لیست مجاورت نگه داری شده است.

در ادامه مطابق با روش gibbs sampling در هر مرحله طابق با روابط به دست آمده ماتریس‌های  $U$  و  $V$  و سپس سیگمای  $U$  و سیگمای  $V$  بر اساس توزیع‌های هر کدام نمونه برداری میشوند.

تفاوت روابط در این مرحله شامل نتایج به دست آمده از روش variational mean field و هم چنین اضافه شدن ماتریس  $W$  است که بیانگر تاثیرگذاری افراد و همسایه‌های آن هاست.

- مقادیر اولیه ماتریس‌های  $U$  و  $V$  و سیگمای  $U$  و سیگمای  $V$  نیز بر اساس توزیع‌های اولیه آن‌ها و با مقادیر اولیه فرایارامترهای  $\sigma, \alpha_U, \alpha_V, \beta_U, \beta_V$  نمونه برداری شده‌اند.

- مقدار اولیه ماتریس  $W$  نیز در ابتدا صفر فرض شده است. به این معنا که در iteration اول کاربران بر روی هم تاثیری ندارند.

- برای هر  $user$  و  $item$  چون مستقل از هم در نظر گرفته شده‌اند بنابراین نمونه برداری ماتریس‌های  $U$  و  $V$  نیز به صورت مستقل بر روی  $user$  و  $item$  انجام شده است.

- توزیع ها به هم وابستگی دارند (به عنوان مثال توزیع  $U$  به میانگین توزیع  $V$  وابسته است). بنابراین با شروع از  $U$  به ترتیب  $V$ ، سیگمای  $U$ ، سیگمای  $V$  و در نهایت  $W$  تخمین زده میشود و تا convergence این کار ادامه میابد. بنابراین نیاز است پارامترهای توزیع ها در هر مرحله شامل  $mean$  ,  $cov$  ها و غیره نگه داری شوند.

محاسبه RMSE مرحله آموزش و هم چنین مقدار خطا بر روی داده validation مطابق با بخش اول انجام شده است.

## بخش چهارم: نتایج


### فراپارامترها:

- تعداد ابعاد latent دو ماتریس  $U$  و  $V$  مقدار 2 انتخاب شد.
- بر اساس چند تست انجام شده و مقایسه میزان خطا مقادیر زیر برای دیگر پارامترها انتخاب شد.

- $\sigma=1, \alpha_U=1, \beta_U=1, \alpha_V=1, \beta_V=1$

### نتایج بخش اول - رویکرد bayesian :

نمودار خطای RMSE در iteration های مرحله آموزش مشاهده میشود.




هم چنین مقدار خطای rmse بر روی داده های validation مطابق با زیر به دست آمده است.

RMSE\_VALIDATION = 4.805378367441022

### نتایج بخش دوم - استفاده از داده‌های شبکه‌های اجتماعی :

مطابق با روابط به دست آمده توزیع های ماتریس های  $U$  و  $V$  و سیگمای  $U$  و سیگمای  $V$  به هم وابستگی داشتند. وابستگی نیز در محاسبه Epectation بر اساس متغیرهای نهان به وجود می آمد که یک راه همان طور که در روابط به دست آمد جایگذاری آن با expectation های توزیع های جدید به دست آمده بود و یک راه جایگذاری با توزیع های اصلی  $U$  و  $V$  که راه دوم نتایج بهتری ایجاد میکرد.

نمودار خطای RMSE در iteration های مرحله آموزش مشاهده میشود.



هم چنین مقدار خطای rmse بر روی داده‌های validation مطابق با زیر به دست آمده است.

RMSE\_VALIDATION = 4.255453720455846

- RMSE آموزش بخش اول از این بخش بهتر است که میتواند به خاطر برتری روش gibbs sampling نسبت به variational mean field در این مسئله باشد.
- نوع مدل سازی و اضافه شدن تاثیر دوستان در امتیازات هر فرد به نظر میرسد که میتواند در بهتر شدن نتیجه تاثیر گذار باشد. ولی در داده‌ی موجود بر این مسئله تعداد حالاتی که یک فرد به item ای امتیاز داده باشد که دوست او نیز به آن item داده باشد در مقایسه با تعداد user ها و item ها بسیار کم است.